# Семинар 5. Репликация и CAP-теорема

## Распределенные вычисления

Георгий Семенов

Институт прикладных компьютерных наук
Университет ИТМО

весна 2026

# Организационные моменты

- Сдвинут DL по первому домашнему заданию – теперь в 23:59 21.03.2026
- Второе домашнее задание – жесткий дедлайн в 23:59 02.04.2026
  - Полностью с автопроверкой (10 баллов за галочку в GitHub Classroom)
  - Штраф за сдачу после дедлайна - 50%

# Содержание


1. Пессимистическая репликация
2. Оптимистическая репликация
3. CAP- и PACELC- теоремы

# Понятие репликации

## Репликация

Избыточное дублирование одного логического объекта на нескольких узлах системы.

- Зачем нужна:
  - **Доступность**: не нужно далеко ходить за данными (данные всегда доступны, даже если другие узлы лежат)
  - **Производительность**: параллелизм на чтение, распределение нагрузки
  - **Георасределение**: доступность в плане географических зон
- Цена репликации:
  - необходимость управлять целостностью данных (integrity)
  - конфликты и неопределенный порядок событий

# Две стратегии репликации

## Стратегия 1: Пессимистическая (синхронная)

Перед тем как ответить клиенту на запись, синхронизируем со всеми репликами.

- Плюс: гарантия что все видят одно и то же
- Минус: запись медленна, если упадет какой-то узел — система не отвечает
- Разрешение конфликтов a priori

## Стратегия 2: Оптимистическая (асинхронная)

Клиенту ответили сразу, дальше все реплики синхронизируются в фоне.

- Плюс: запись быстра, система отвечает даже если узлы падают
- Минус: временно разные реплики видят разные значения
- Разрешение конфликтов a posteriori

# Пессимистическая репликация

## Пессимистическая репликация

Синхронная репликация: все изменения синхронизируются **до** ответа клиенту.

- Почему она называется «пессимистической»?
  - Инварианты не могут быть временно нарушены
  - Баланс счета не должен уйти в минус даже временно
  - Логин/email должны быть уникальны *сейчас*
  - Ограничения внешних ключей
- Как работает пессимистическая репликация:
  - Координатор (мастер) синхронизирует запись со всеми репликами
  - Используется quorum/consensus: большинство должны подтвердить
  - Только когда большинство согласны, клиент получает ответ
- Типичные механизмы:
  - Distributed locks (мьютекствуло между узлами)
  - Consensus/quorum (Raft, Paxos)
  - Two-Phase Commit (2PC)

# Транзакционная модель ACID

То, какие данные и с какой целью реплицируются, – это детали реализации системы. Внешняя модель согласованности, свойственная пессимистическим транзакциям, – это ACID:

- **Atomicity**: транзакция либо целиком применена, либо откат
- **Consistency**: переход между корректными состояниями БД
- **Isolation**: параллельные транзакции не мешают и не заметны друг другу
- **Durability**: после commit данные переживают сбой узла (WAL)

**Важно**

ACID — это свойства *модели выполнения транзакций*, а не «strong consistency». Но сам подход является пессимистическим.

# Linearizability и One-Copy Serializability (1SR)

- **Linearizability**:
  - каждая операция выглядит как мгновенная в момент между invoke/response
  - если A завершилась раньше, чем B началась, то A должна быть раньше B в глобальном порядке
  - модель «поведения одной корректной копии в реальном времени»
- **One-Copy Serializability (1SR)**:
  - итог эквивалентен некоторому последовательному порядку транзакций над одной копией
  - не требует сохранения реального времени между независимыми транзакциями

**Комментарий**

Linearizability – для атомарных операций записи/чтения,
1SR-Serializability – для транзакций.

# Блокировка

## Понятие блокировки

Механизм, ограничивающий параллельный доступ к данным для обеспечения их согласованности:

- **Shared (S)** — читать можно многим, писать не может никто
- **Exclusive (X)** — читать и писать может только один

- Централизованный координатор блокировок
  - **coordinator lock service** (например, ZooKeeper/etcd)
  - модель check-in/check-out
  - single point of failure, но может децентрализованным с помощью consensus
- Two-Phase Locking (2PL):
  - growing phase: только захватываем lock'и
  - shrinking phase: только освобождаем
- Риски: deadlocks, high contention (дисциплина обслуживания)

# Распределенная блокировка

## Понятие распределенной блокировки

Блокировка на некоторое время (TTL = Time-to-Live) между узлами в распределенной системе.

## Fencing token

Монотонно растущий номер владения lock'ом; хранилище обязано отклонять устаревшие токены.

- **lease-based lock** с TTL
- Практика: lock + idempotency + timeout + retry с backoff

# Rate Limiter с помощью распределенной блокировки

**Задача:** ограничить количество запросов одного пользователя до N в минуту.

## Наивный подход с глобальной блокировкой

Для каждого пользователя есть счетчик `cnt[user]`. При каждом запросе:

1. захватить `lock[user]` (прежде чем трогать счетчик)
2. прочитать `cnt[user]`
3. если `cnt[user] < N`: инкрементировать, разрешить запрос
4. иначе: отклонить (HTTP 429 Too Many Requests)
5. освободить `lock[user]`

# Optimistic Concurrency Control (OCC)

Позволяем тразакциям конкурировать, но проверяем их на конфликт в момент commit. Если конфликт — отклоняем одну из транзакций.

## Пример сценария

Сотрудник Alice и сотрудник Bob редактируют зарплату одного человека.

- Alice читает: `salary = 50000`, версия `v=5`
- Bob читает: `salary = 50000`, версия `v=5`
- Alice пишет: update to 55000 где `v=5`
- Bob пишет: update to 52000 где `v=5`

Из этих двух обновлений только одно может быть принято.

## Увлекательный аспект

Техника называется оптимистической, потому что предполагает, что конфликты редки и не стоит блокировать ресурсы заранее. Но она пессимистическая, потому что в момент commit мы pessimistically проверяем, что никто не изменил данные с момента чтения.

# Содержание


1. Пессимистическая репликация
2. Оптимистическая репликация
3. CAP- и PACELC- теоремы

# Оптимистическая репликация

## Оптимистическая репликация

Репликация, при которой мы оптимистически разрешаем write-обновления на репликах без предварительной синхронизации.

- Как это работает:
  - У каждого узла системы есть своя реплика данных
  - Чтение и запись производятся с локальной реплики, без синхронизации
  - Состояния синхронизируются синхронно (gossip, anti-entropy)
- Как работать с конфликатми:
  - Детерминированно их разрешать без синхронизации (CRDT)
  - Полуавтоматически и централизованно (семантическая реконсиляция)
  - Полностью ручной централизованной merge

# Транзакционная модель BASE

- **Basically Available**: данные доступны для чтения и записи на узле даже при сбоях других узлов
- **Soft state**: состояние всегда спекулятивное, т.е. мы читаем не «последнее», а «какое-то» значение
- **Eventually consistent**: при отсутствии новых записей реплики сходятся

## ACID vs BASE

ACID оптимизирует корректность синхронного commit, BASE — доступность и масштаб в условиях partition.

# Статья 'Optimistic Replication': M. Shapiro et al. (2005)

- Ввела общий язык для optimistic replication и reconciliation
- Ключевые оси классификации:
  - state-transfer vs operation-transfer
  - синхронная vs асинхронная доставка
  - автоматический vs ручной merge
- Главный вывод: нельзя «бесплатно» получить сразу простоту, низкую задержку и сильную согласованность
- Практика: проектировать **типы данных и операции** под возможные конфликты заранее

# Схема оптимистической репликации

*Y. Saito and M. Shapir*

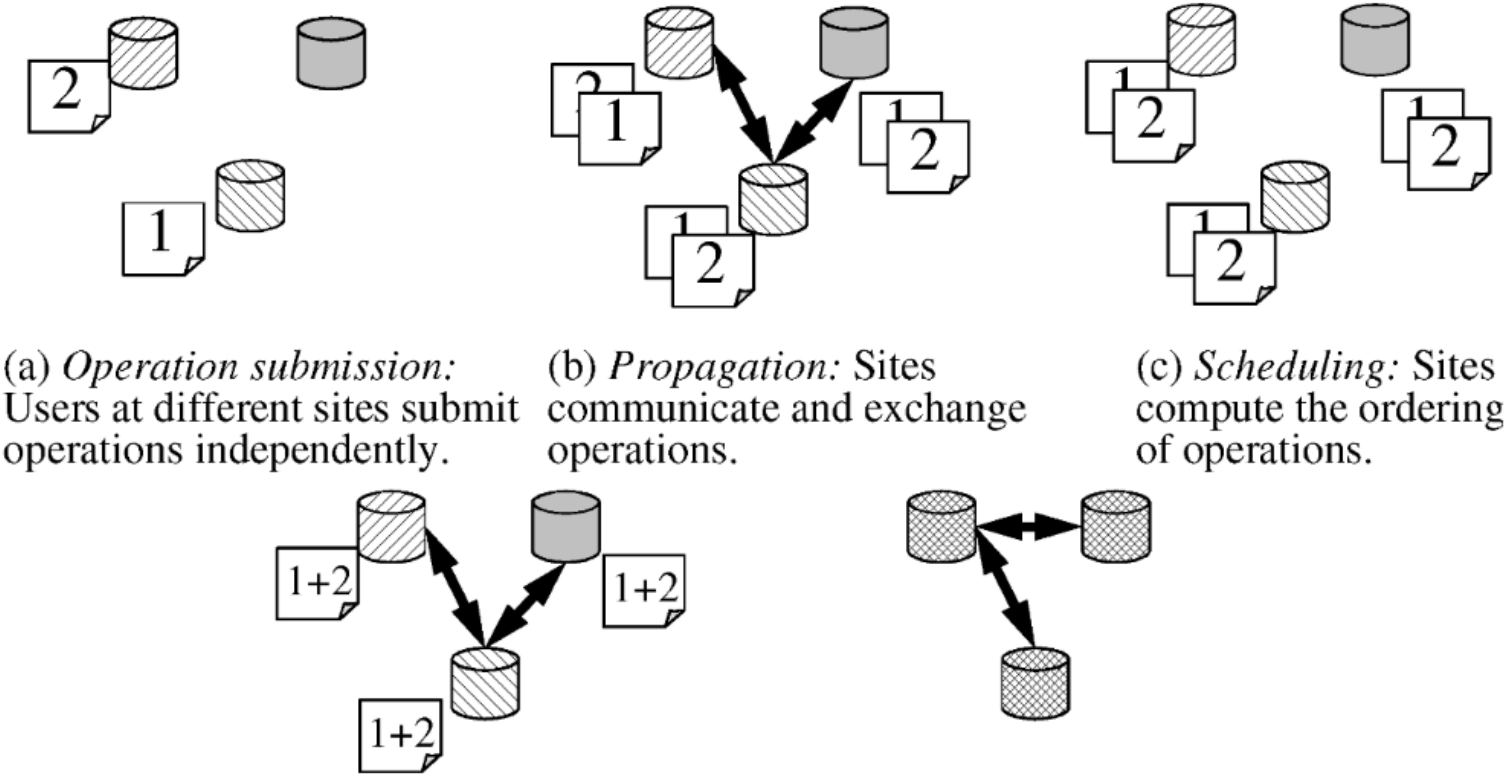


(a) *Operation submission:* Users at different sites submit operations independently.

(b) *Propagation:* Sites communicate and exchange operations.

(c) *Scheduling:* Sites compute the ordering of operations.

(d) *Conflict resolution:* Sites detect conflicts and transform offending operations to produce results intended by users.

(e) *Commitment:* Sites agree on the final ordering and reconciliation result. Their changes become permanent.

**Fig. 1.** Elements of optimistic replication and their roles. Disks represent replicas, memo sheets represent operations, and arrows represent commu-

# Знакомые до боли векторные часики

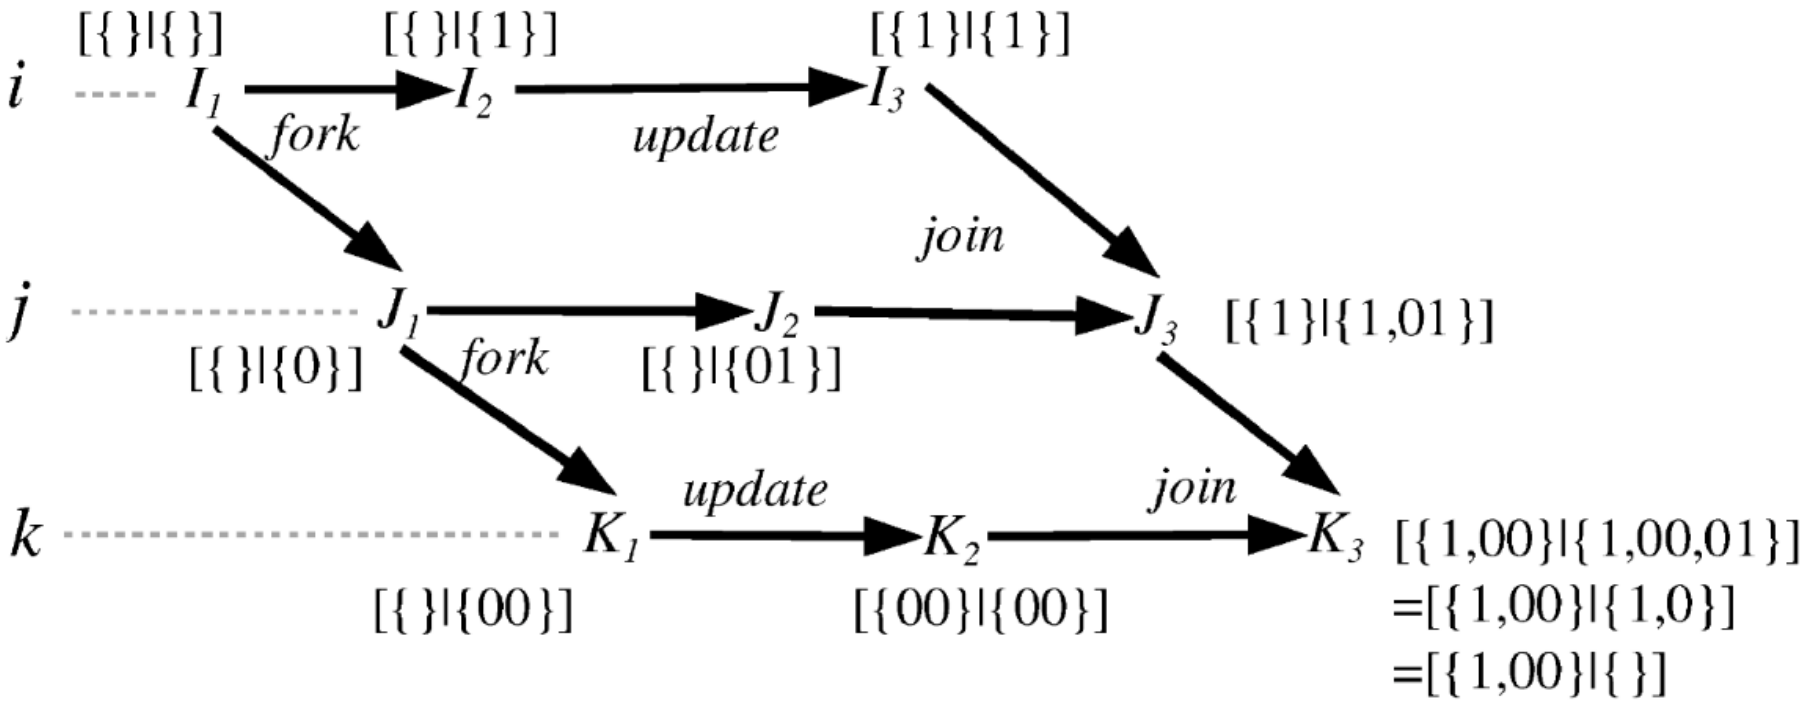


**Fig. 13**. Example of the use of version timestamps (VTs). An object starts as a single replica $I_1$ with a VT of [{}|{}]. It is forked into two replicas $I_2$ and $J_1$. Site $i$ updates the replica, which becomes $I_3$. Merging replicas $I_3$ and $J_2$ detects no conflict as $I_3$ dominates $J_2$, as apparent from the fact that $\{1\} \supset \{\}$. In contrast, concurrent updates are detected when merging replicas $J_3$ and $K_2$ as neither of the upd-ids, {00} and {1}, subsumes the other.

# Модель Amazon DynamoDB и прикол с корзиной покупок

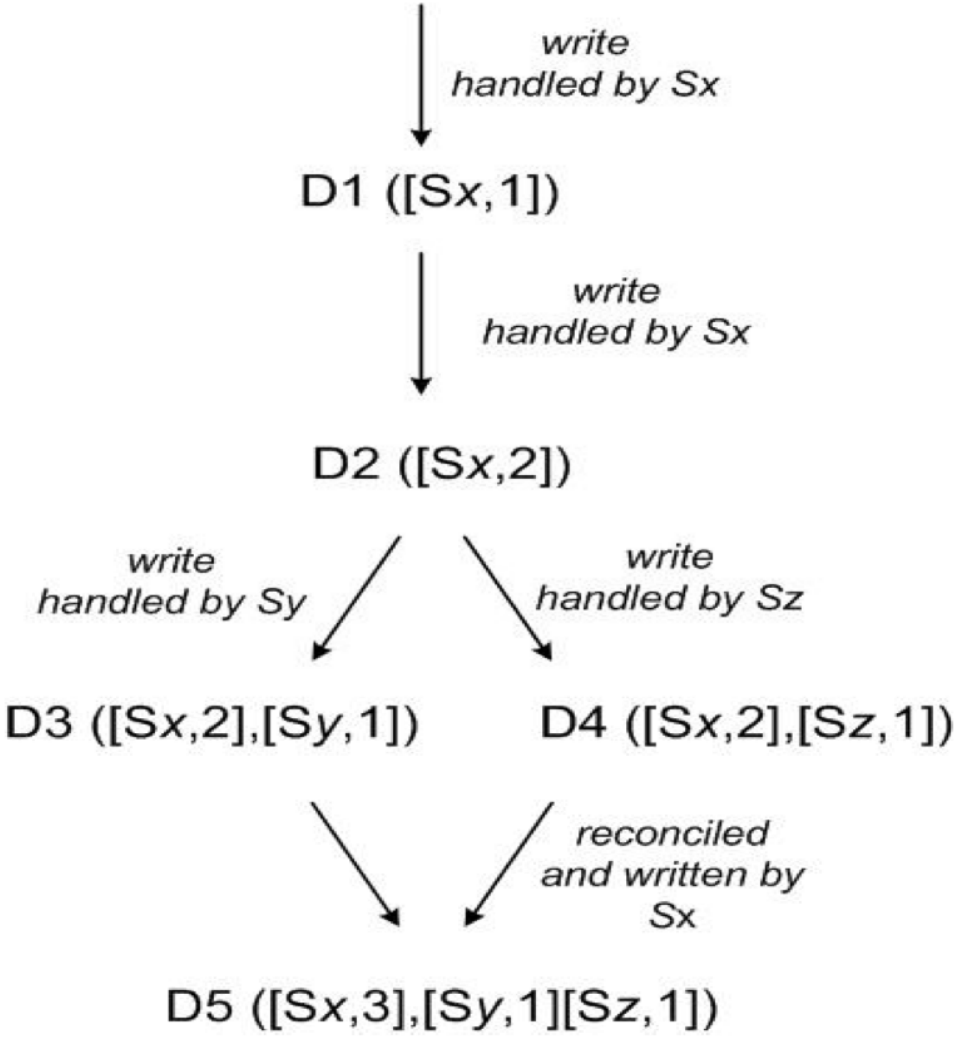


**Figure 3: Version evolution of an object over time.**

# Содержание

1 Пессимистическая репликация

2 Оптимистическая репликация

3 CAP- и PACELC- теоремы

# Почему две стратегии, а не одна?

- Ранее мы увидели два **противоположных** подхода к репликации
- Пессимистический: жертвуем доступностью и задержкой за консистентность
- Оптимистический: жертвуем консистентностью за доступность и задержку

## Три невозможных желания

Нельзя одновременно гарантировать:

- **C**onsistency: все видят одно и то же
- **A**vailability: система всегда отвечает
- **P**artition tolerance: система работает когда сеть разломана

# Необходимые понятия

**Network partition** — когда узлы перестают иметь возможность коммуницировать

- **Consistency (C)**: все клиенты видят единое согласованное состояние
- **Availability (A)**: каждый корректный запрос получает ответ
- **Partition tolerance (P)**: система продолжает работу при потере связности между узлами
- **Latency (L)** — время ответа на запрос

**Деталь**

В CAP под C обычно понимают поведение, близкое к linearizability.

# CAP-теорема

## CAP-теорема (Brewer, 2000; Gilbert & Lynch, 2002)

В системе нельзя одновременно гарантировать (max 2/3):

- **C**onsistency: сильная согласованность данных
- **A**vailability: доступность
- **P**artition tolerance: устойчивость к сетевым разрывам

# Детали про CAP-теорему

- **CP**: отклоняем часть запросов, но не отдаем противоречивые ответы
- **AP**: отвечаем всегда, но допускаем временную рассогласованность

## Классы систем

Любая система относится либо к CP (пессимистическая), либо к AP (оптимистическая).

## Важный момент

CA-система возможна только если игнорировать partition как класс сбоев, что наивно.

# 'Critique of CAP theorem' (Kleppmann, 2014)

- Сетевые разрывы – это настолько очевидный тип отказа, что глупо говорить отдельно, что мы можем его игнорировать (P)
- По факту выбираем между C и A, при этом упускаем измерение L (latency)
- Подход Клеппманна:
  - Разделим операции на delay-dependent и delay-independent
  - Для delay-independent операций можно достичь и C, и A
  - Иначе выбираем C или A в зависимости от требований к задержке

# PACELC-теорема

- **If P** (partition): выбор между **A** и **C**
- **Else** (нет partition): выбор между **L** (latency) и **C**
- Примеры:
  - **PA/EL**: Dynamo-подобные системы (в норме низкая задержка)
  - **PC/EC**: системы, жертвующие latency ради строгой согласованности

# Итоги

- (!) Выдано второе домашнее задание
- Обсудили понятие репликации и две противоположные стратегии: пессимистическую и оптимистическую
- CAP-теорема иллюстрирует, почему важны и нужны оба подхода